Звіт з лабораторної роботи. Порівняння класичного машинного навчання, глибокої нейронної мережі та трансформера на задачі розпізнавання стресу і фізичного навантаження за сигналами браслета

Дисципліна: «Штучний інтелект: принципи і методи»

Виконав: Луковський Максим, група ШІ-1

1. Вступ

1.1. Постановка задачі

Задача роботи: за 30-секундним відрізком сигналів наручного браслета Empatica E4 визначити стан людини в цьому відрізку. Це багатокласова класифікація багатоканальних часових рядів на три класи:

- 0: спокій;
- 1: психологічний стрес (когнітивні й емоційні завдання, публічний виступ);
- 2: фізичне навантаження (велотренажер).

Вхід X: вікно з п'яти сигналів браслета (електродермальна активність, об'ємний пульс, пульс, температура шкіри, прискорення). Ціль y: мітка класу для вікна.

1.2. Актуальність

Браслети на кшталт Empatica E4 або звичайних фітнес-трекерів носять цілодобово, і автоматичне розпізнавання стресу потрібне для моніторингу здоров'я, рекомендацій щодо відпочинку та досліджень вигорання. Складність задачі в тому, що пульс і провідність шкіри зростають і під час стресу, і під час навантаження, браслет дає лише периферійні сигнали невисокої якості, а реакція різних людей на ті самі подразники сильно відрізняється.

1.3. Мета і завдання

Мета: з'ясувати, який рівень складності моделі виправданий для цієї задачі, якщо враховувати не лише якість, а й час, пам'ять, кількість параметрів і стабільність.

Завдання:

1. Підготувати датасет: сегментація, перевірка даних, ознаки, персональне калібрування.
2. Зафіксувати єдиний протокол оцінювання до навчання першої моделі.
3. Навчити й оцінити три моделі трьох рівнів складності: XGBoost над ручними ознаками, одновимірну згорткову мережу над сирими сигналами та попередньо навчений трансформер для часових рядів MOMENT-1 з частковим донавчанням.
4. Порівняти моделі за якістю, ціною, стабільністю та характером помилок, зіставити з літературою і зробити висновок про виправданий рівень складності.

2. Датасет

2.1. Джерело та зміст

Використано Wearable Device Dataset from Induced Stress and Structured Exercise Sessions, версія 1.0.1, опублікований на PhysioNet (DOI 10.13026/zzf8-xv61) під ліцензією ODC-By 1.0 і описаний у статті Hongn et al., Scientific Data 12:520 (2025).

- 36 здорових дорослих, до трьох сесій на людину: стрес-протокол (базовий рівень, завдання, відпочинки; два варіанти V1 і V2), аеробне тренування близько 35 хв, анаеробне тренування зі спринтами Вінгейта.
- Прилад Empatica E4 на зап'ясті. Межі етапів протоколу записані в tags.csv; протокол V1 має 12 тегів, V2 має 9, тому номери тегів задані окремо.
- Автори вказали чотири дефектні записи, які виключено: S02 (продубльовані сигнали), f07 (накладка закривала датчики), f14_a (лише базовий рівень, решта у f14_b), S11_b (один тег).

Сигнал	Частота	Що вимірює
EDA	4 Гц	електродермальна активність (провідність шкіри)
BVP	64 Гц	об'ємний пульс (фотоплетизмографія)

Сигнал	Частота	Що вимірює
HR	1 Гц	пульс, обчислений пристроєм
TEMP	4 Гц	температура шкіри
ACC	32 Гц	прискорення по трьох осях

2.2. Сегментація та розмітка

У стрес-сесії завдання між тегами отримують клас 1, відпочинки клас 0, причому з відпочинків після завдань береться лише друга половина, як у Hongn et al., щоб не захопити залишкове збудження. Сесії на велотренажері цілком отримують клас 2. Усі записи ріжуться на вікна по 30 с без перекриття, тож один і той самий відрізок сигналу не може потрапити і в навчання, і в перевірку.

2.3. Перевірка даних

Пропуски. Вікно відкидається, якщо в ньому менше 10 надійних інтервалів між ударами серця або немає відліків HR чи EDA. Таких вікон 21. Два учасники без стрес-сесії відпадають на етапі калібрування, бо для них немає опорної норми.

Дублікати. Запис S02 виключений; повних дублікатів серед рядків ознак немає (перевірено, 0).

Баланс. Після фільтрації 3592 вікна від 34 учасників.

Сесія	Спокій	Стрес	Навантаження
STRESS	753	370	0
AEROBIC	0	0	1585
ANAEROBIC	0	0	1050
Разом	753	370	2635

Клас навантаження у 7 разів більший за клас стресу: сесії на велотренажері довгі й цілком належать одному класу, а стрес-завдання короткі. Тому під час навчання всюди застосовано ваги класів, обернені до частоти, а головною метрикою обрано macro-F1.

2.4. Ознаки для класичної моделі

З BVP (64 Гц): смуговий фільтр 0,5–8 Гц, пошук западин, інтервали між ударами; інтервали коротші за 0,33 с або довші за 1,5 с відкидаються як артефакти. З EDA (4 Гц): тонічна складова фільтром 0,05 Гц і сплески провідності (SCR) поверх неї. На вікно обчислюється 12 ознак.

Ознака	Зміст
eda_mean, eda_slope	рівень провідності шкіри та її нахил у вікні
scr_per_min, scr_amplitude	кількість і сумарна амплітуда сплесків провідності
hr_mean, hr_std	середній пульс і його розкид
ibi_mean, sdnn, rmssd	середній інтервал між ударами і два показники варіабельності ритму
temp_mean	температура шкіри
acc_mean, acc_std	модуль прискорення зап'ястя і його розкид

2.5. Вхід для нейронних мереж

Для мереж вікно подається як сирий багатоканальний ряд без ручних ознак: EDA, TEMP, HR, модуль ACC та інтервали між ударами серця, інтерпольовані до 4 Гц, масив 5 × 120. Канал інтервалів дає мережам доступ до варіабельності ритму, яку ознаки беруть із BVP на 64 Гц.

2.6. Персональне калібрування

Кожна ознака і кожен канал переводяться у відхилення від норми учасника: мінус середнє його стрес-сесії, поділити на стандартне відхилення. Калібрування не використовує міток, і інформація між учасниками не перетікає. Так само роблять Hongn et al. і Schmidt et al. Фізичне навантаження при такому калібруванні дає дуже великі відхилення пульсу, що й робить цей клас легким.

3. Огляд літератури

Робота	Дані і поділ	Модель	Результат	Що взято в роботу
Hongn et al., 2025, Scientific Data	цей датасет; 1 приклад = етап протоколу; 10-fold з випадковим поділом, oversampling	XGBoost, 49 ознак, скорочених до 13–19	стрес/спокій accuracy 93 %, F1 92 %; 4 класи accuracy 84 %, F1 84 %	набір ознак, друга половина відпочинків, нормалізація в межах учасника, налаштування XGBoost
Schmidt et al., 2018, ICMI (WESAD)	15 учасників, Empatica E4 + нагрудний датчик, вікна 60 с, leave-one-subject-out	дерева, RF, AdaBoost, LDA, kNN над ознаками	зап'ястя, 3 класи: RF F1 66,3, accuracy 76,2	перелік ознак зап'ястя, поділ по учасниках як еталон чесної перевірки, macro-F1 для дисбалансу
Dzieżyc et al., 2020, Sensors	WESAD, 14 сигналів, вікна 60 с, 5-fold по учасниках	10 наскрізних мереж на сирих сигналах: FCN, ResNet, Time-CNN та ін.	FCN accuracy 0,79 ± 0,05, F1 0,73 ± 0,07; мережі не кращі за ознаки	архітектура згорткової мережі (спрощена FCN), 5-fold по учасниках
Goswami et al., 2024, ICML (MOMENT)	попереднє навчання на Time Series Pile; класифікація перевірена на архіві UCR	encoder T5 над патчами по 8 відліків, вікно 512; розміри Small, Base, Large	точніша за 11 із 16 методів без донавчання encoder	готова foundation-модель для рівня 3, донавчання замість навчання з нуля
Kaya et al., 2026, arXiv	6 учасників, браслет + камера, вікна 10 хв, leave-one-participant-out	класичні моделі та MOMENT	лише браслет: accuracy 77,8 %, recall стресу 50 %, MOMENT 54 %	підтвердження, що MOMENT на сигналах браслета поступається класичним моделям

З огляду випливають три висновки, які визначили протокол роботи. По-перше, високі числа авторів датасету отримані при випадковому поділі, коли приклади однієї людини потрапляють і в train, і в test; при поділі по учасниках результати в усіх роботах помітно нижчі, тому в цій роботі дані діляться лише по учасниках. По-друге, на датасетах із кількома десятками учасників глибокі мережі не дають переваги над класичними моделями над ознаками, і це гіпотеза, яку робота перевіряє. По-третє, foundation-модель для часових рядів уже пробували на сигналах браслета, і в роботі Kaya et al. вона поступилася класичним моделям; серед відкритих моделей лише MOMENT має класифікаційну постановку і багатоканальний вхід, Chronos і TimesFM навчені лише на прогноз.

4. Методологія

Протокол зафіксовано до навчання першої моделі, і він однаковий для всіх трьох: ті самі вікна, ті самі поділи, та сама процедура оцінювання, яка виконує 5 запусків, рахує метрики, заміряє час навчання й inference та пік пам'яті.

4.1. Поділ даних

П'ятикратна перехресна перевірка GroupKFold із групуванням по учасниках: усі вікна однієї людини потрапляють або в навчальну, або в перевірочну частину. У кожному прогоні модель навчається на 27 учасниках і перевіряється на 7 небачених. Це відповідає реальному сценарію застосування моделі до нового користувача і виключає витік даних між сусідніми вікнами. Групи однакові для всіх моделей, тому їх результати можна порівнювати по кожній групі окремо.

Окремої валідаційної частини немає: при 34 учасниках вона лишила б мережам близько 20 людей для навчання. Усі гіперпараметри зафіксовані заздалегідь з літератури (розділи 5–7) і не підбиралися за результатами на перевірочних групах, тому перевірочні групи виконують роль тестової вибірки.

4.2. Метрики

Якість: accuracy, precision, recall, macro-F1, F1 по кожному класу, нормалізована матриця плутанини. Головна метрика macro-F1, бо класи незбалансовані. Accuracy і macro-F1 подаються як середнє по 5 групах, F1 по класах обчислено по зведених прогнозах усіх груп.

Ціна: час підготовки даних, час навчання (сума за 5 запусків), час inference на одне вікно, пікове споживання пам'яті (фоновий потік опитує RSS процесу кожні 20 мс), кількість параметрів (для XGBoost кількість вузлів дерев), розмір моделі на диску, потреба в GPU.

Стабільність: стандартне відхилення метрик по 5 групах і таблиця macro-F1 для кожної групи. Випадковість зафіксовано: seed 42 для поділу та XGBoost, seed 0 для PyTorch.

4.3. Апаратне та програмне забезпечення

Apple M4, 16 GB RAM, вбудований GPU через MPS. Python 3.15, PyTorch, xgboost, momentfm. XGBoost і згорткова мережа навчалися на одному потоці CPU: xgboost і torch на macOS вантажать кожен свою копію OpenMP, при багатопотоковій роботі обох процес зависає, а один потік вирівнює заміри часу. MOMENT навчався на GPU, бо прохід 35-мільйонної моделі по вікнах на CPU тривав би десятки хвилин на кожен запуск. Пакет momentfm встановлено без залежностей, бо він закріплює застарілі numpy і transformers, несумісні з Python 3.15.

5. Модель 1: XGBoost над ручними ознаками

Класичний рівень: градієнтний бустинг XGBoost з налаштуваннями Hongn et al.: 400 дерев глибини 3, швидкість навчання 0,05, підвибірка 0,8 по рядках і стовпцях, ваги класів. Вхід: 12 ручних ознак (розділ 2.4). Ансамбль неглибоких дерев ловить взаємодії ознак: високий пульс при малому русі означає стрес, при великому означає навантаження.

Метрика	Значення
Accuracy	0,902 ± 0,015
Macro-F1	0,801 ± 0,016
F1 спокій / стрес / навантаження	0,815 / 0,614 / 0,978
Recall спокій / стрес / навантаження	0,809 / 0,692 / 0,962
Час навчання, 5 запусків	1,0 с
Inference на вікно	0,004 мс
Пік пам'яті	0,6 MB
Складність	15 992 вузлів дерев, 1,3 MB на диску, GPU не потрібен

6. Модель 2: одновимірна згорткова мережа

Глибокий рівень: мережа над сирим вікном 5 × 120 без ручних ознак, спрощена FCN з Dzieżyc et al. Три згорткові шари (32, 64, 64 фільтри; ядра 5, 5, 3) з BatchNorm і ReLU, після перших двох max-pooling удвічі, далі усереднення по часу, dropout 0,3 і лінійний вихід на 3 класи. Усього 23 683 параметри. Навчання: Adam 0,001, 30 епох, батч 64, крос-ентропія з вагами класів, CPU.

Метрика	Значення
Accuracy	0,875 ± 0,024
Macro-F1	0,768 ± 0,027
F1 спокій / стрес / навантаження	0,773 / 0,557 / 0,967
Recall спокій / стрес / навантаження	0,737 / 0,705 / 0,942
Час навчання, 5 запусків	151,7 с
Inference на вікно	0,31 мс
Пік пам'яті	1,0 MB
Складність	23 683 параметри, 96 KB на диску, GPU не потрібен

7. Модель 3: трансформер MOMENT-1 з частковим донавчанням

7.1. Модель

MOMENT-1 (Goswami et al., ICML 2024): відкрита foundation-модель для часових рядів, encoder T5, попередньо навчений відновлювати замасковані відрізки на корпусі Time Series Pile. Ряд довжиною 512 ріжеться на 64 патчі по 8 відліків, канали обробляються незалежно. Узято розмір Small: 35,3 млн параметрів, 8 блоків encoder, d_model 512. Відповідно до методичних вимог модель не навчається з нуля, а адаптується: трансформер з нуля на 34 учасниках не мав би звідки взяти загальні уявлення про форму сигналів.

7.2. Адаптація та навчання

Вікно 5 × 120 лінійно ресемплюється до 512 відліків, тому encoder бачить увесь свій контекст без доповнення нулями. Вихід encoder (64 патчі × 2560, тобто d_model × 5 каналів) усереднюється по патчах, зверху лінійна голова з dropout 0,1. Донавчаються останні 2 з 8 блоків encoder, кінцева нормалізація і голова, разом 4 728 835 параметрів (13 %); перші 6 блоків і патч-embedding заморожені. Навчання: Adam 0,0001, 8 епох, батч 64, крос-ентропія з вагами класів, GPU через MPS. Dropout усередині attention вимкнений, бо MPS не підтримує його в scaled_dot_product_attention. Це формат «легке донавчання готової моделі»: повне донавчання 35 млн параметрів на 2900 вікнах перенавчилося б і коштувало б у кілька разів більше часу.

Метрика	Значення
Accuracy	0,819 ± 0,041
Macro-F1	0,680 ± 0,039
F1 спокій / стрес / навантаження	0,686 / 0,427 / 0,931
Recall спокій / стрес / навантаження	0,640 / 0,538 / 0,914
Час навчання, 5 запусків	2 261,9 с (38 хв)
Inference на вікно	12,9 мс
Пік пам'яті	387,5 MB
Складність	35 345 091 параметрів (навчено 4 728 835), 148 MB на диску, GPU потрібен

Попередній прогін із повністю замороженим encoder і лише лінійною головою (7,7 тис. параметрів, вхід доповнений нулями до 512) дав accuracy 0,801 ± 0,026 і macro-F1 0,682 ± 0,040. Донавчання двох блоків підняло accuracy і F1 навантаження (0,90 → 0,93), але macro-F1 не змінило.

8. Результати

8.1. Єдина підсумкова таблиця

Модель	Вхід	Accuracy	Macro-F1	F1 спокій	F1 стрес	F1 навант.	Навчання, с	Inference, мс	Пам'ять, MB	Параметрів	Розмір	GPU
XGBoost	12 ознак	0,902 ± 0,015	0,801 ± 0,016	0,815	0,614	0,978	1,0	0,004	0,6	15 992 вузлів	1,3 MB	ні
Згорткова мережа	сире вікно 5 × 120	0,875 ± 0,024	0,768 ± 0,027	0,773	0,557	0,967	151,7	0,31	1,0	23 683	96 KB	ні
MOMENT-1 (донавчання)	сире вікно, ресемпл до 512	0,819 ± 0,041	0,680 ± 0,039	0,686	0,427	0,931	2 261,9	12,9	387,5	35,3 млн (навчено 4,7 млн)	148 MB	так

Підготовка даних займає 5,4 с і спільна для всіх моделей.

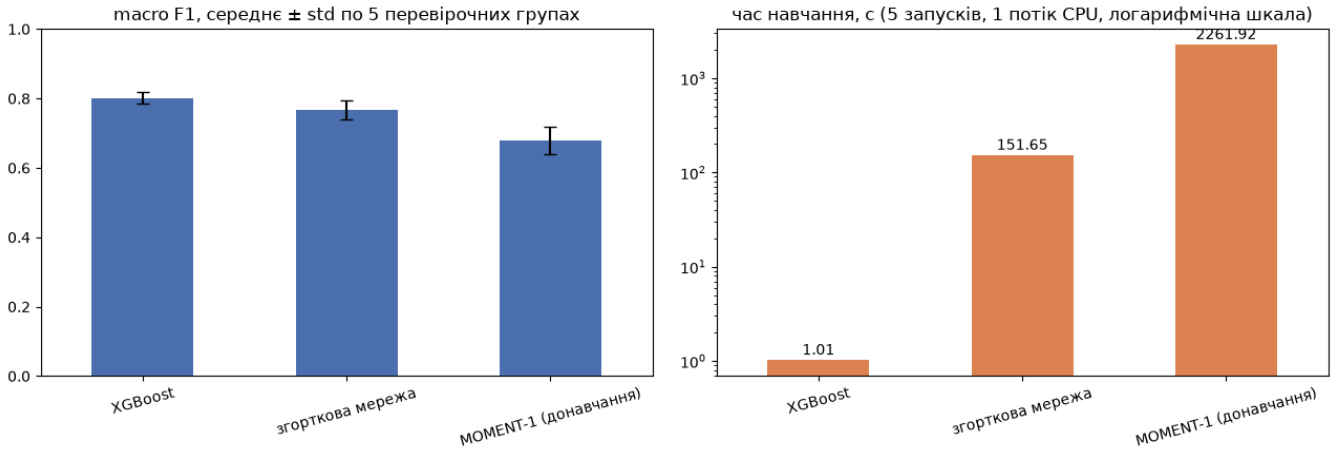


Рис. 1. Accuracy і macro-F1 трьох моделей, середнє ± стандартне відхилення по п'яти перевірочних групах.

8.2. Матриці плутанини

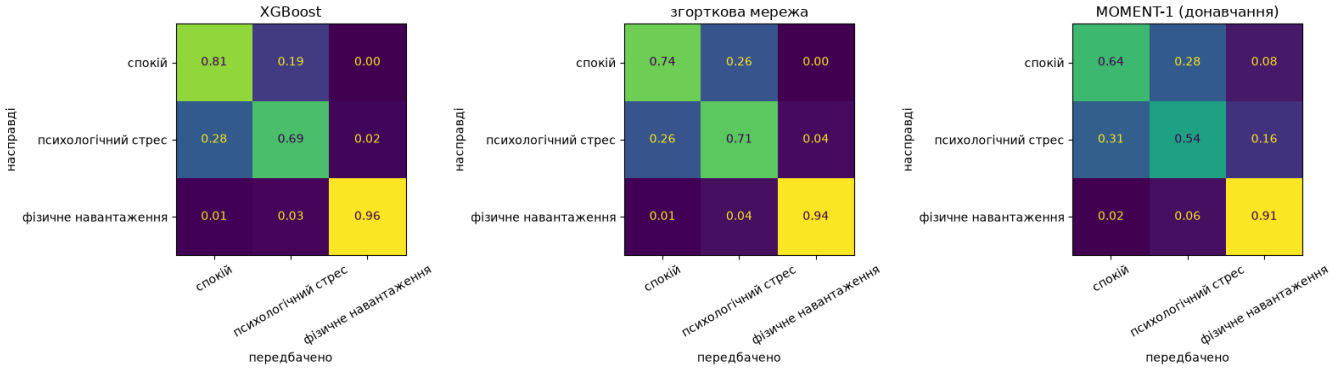


Рис. 2. Нормалізовані матриці плутанини трьох моделей по зведених прогнозах п'яти груп.

Recall по класу	XGBoost	Згорткова мережа	MOMENT-1
Спокій	0,809	0,737	0,640
Психологічний стрес	0,692	0,705	0,538
Фізичне навантаження	0,962	0,942	0,914

8.3. Стабільність по перевірочних групах

Модель	Група 1	Група 2	Група 3	Група 4	Група 5	Діапазон
XGBoost	0,807	0,815	0,785	0,784	0,817	0,78–0,82
Згорткова мережа	0,791	0,728	0,759	0,793	0,769	0,73–0,79
MOMENT-1	0,731	0,624	0,698	0,675	0,672	0,62–0,73

Порядок моделей однаковий у всіх п'яти групах, розкид зростає зі складністю моделі.

8.4. Trade-off: якість проти ціни

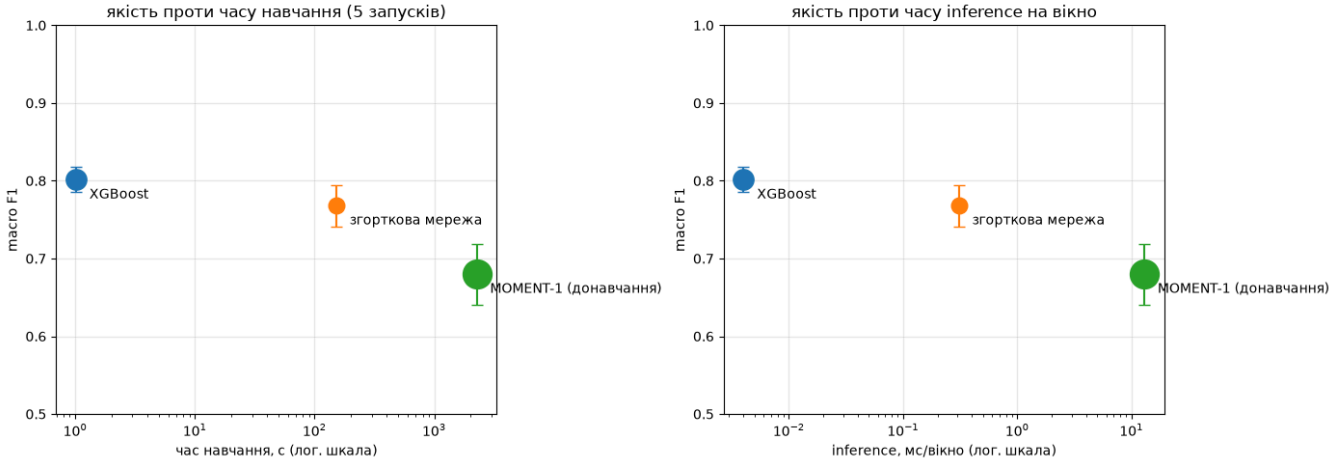


Рис. 3. Macro-F1 проти часу навчання та часу inference у логарифмічній шкалі. Розмір маркера пропорційний логарифму розміру моделі на диску. Корисна модель має бути вгорі ліворуч.

8.5. Важливість ознак XGBoost

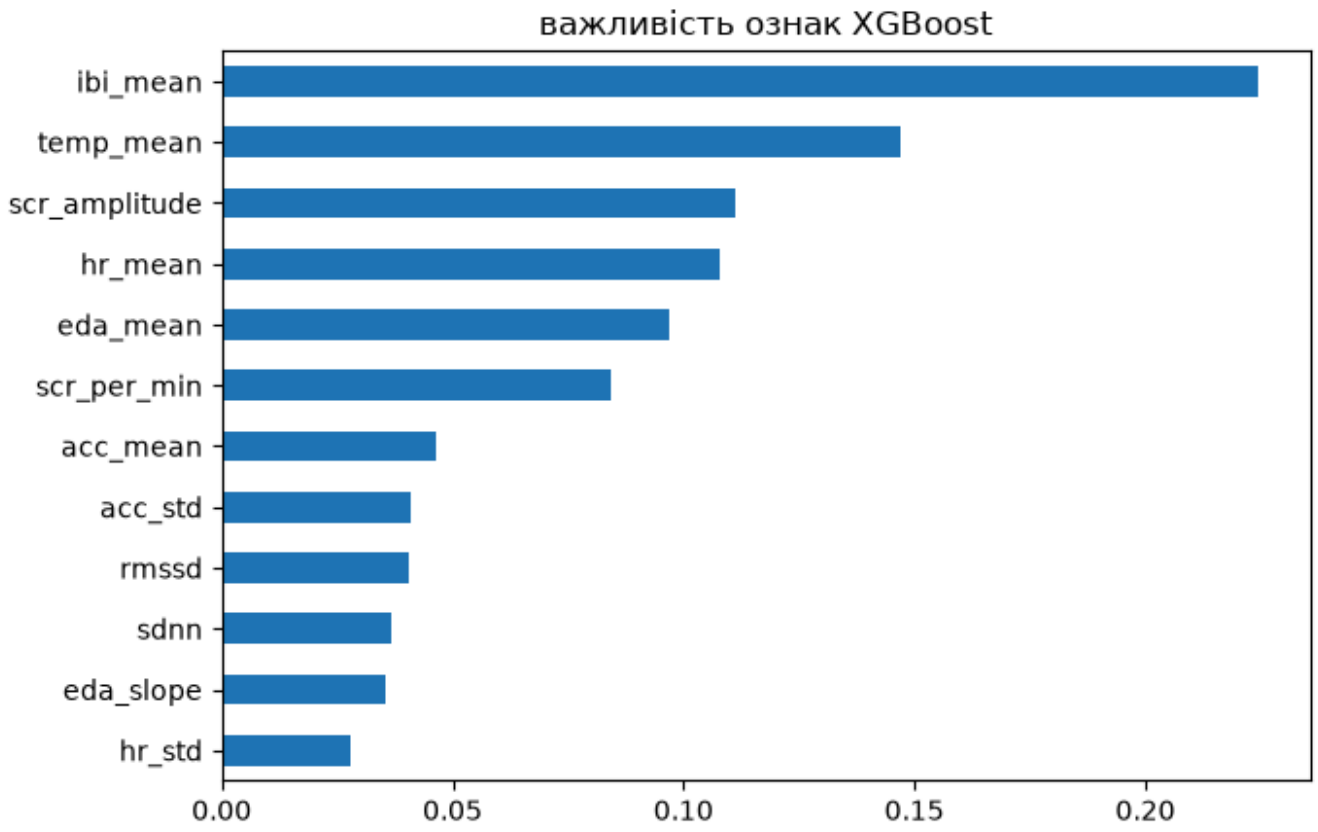


Рис. 4. Важливість ознак XGBoost за приростом (gain).

Ознака	Важливість
ibi_mean	0,225
temp_mean	0,147
scr_amplitude	0,111
hr_mean	0,108
eda_mean	0,097
scr_per_min	0,084
acc_mean	0,047
acc_std	0,041
rmssd	0,040
sdnn	0,037
eda_slope	0,036
hr_std	0,028

8.6. Порівняння з літературою

Робота	Протокол	Їхній результат	Наш найближчий результат
Hongn et al., 2025 (цей датасет)	10-fold, випадковий поділ, 1 приклад = етап протоколу	4 класи: accuracy 84 %, F1 84 %	3 класи, поділ по учасниках, вікна 30 с: XGBoost accuracy 90,2 %, macro-F1 80,1 %
Schmidt et al., 2018 (WESAD, зап'ястя)	leave-one-subject-out, вікна 60 с	3 класи: RF accuracy 76,2, F1 66,3	XGBoost accuracy 90,2, macro-F1 80,1
Dzieżyc et al., 2020 (WESAD)	5-fold по учасниках, вікна 60 с	FCN accuracy 0,79 ± 0,05, F1 0,73 ± 0,07	згорткова мережа: accuracy 0,88 ± 0,02, macro-F1 0,77 ± 0,03

Робота	Протокол	Їхній результат	Наш найближчий результат
Goswami et al., 2024 (MOMENT)	linear probing на архіві UCR	точніша за 11 із 16 методів	донавчання 2 блоків: accuracy 0,82 ± 0,04, macro-F1 0,68 ± 0,04
Kaya et al., 2026 (6 учасників)	leave-one-participant-out, вікна 10 хв	лише браслет: accuracy 77,8 %, recall стресу 50 %	recall стресу: XGBoost 69 %, мережа 70 %, MOMENT 54 %; accuracy 82–90 %

Прямого аналога нашої постановки (спокій / психологічний стрес / фізичне навантаження з поділом по учасниках) у літературі немає, тому порівняння наближене. Наші числа потрапляють у той самий діапазон або вище, ніж роботи з чесним поділом по учасниках (Schmidt, Dzieżyc, Kaya). Числа Hongn et al. отримані з випадковим поділом, де приклади однієї людини потрапляють і в навчання, і в перевірку, тому вони з нашими не порівнювані.

9. Аналіз

9.1. Якість

Відрив XGBoost від згорткової мережі (0,03 macro-F1) більший за розкид і повторюється на всіх п'яти групах. Відрив від MOMENT (0,12) у кілька разів більший за розкид. Отже, порядок моделей не випадковий.

9.2. Чому ознаки виграють

Мережа не бачить ознак і все одно підходить близько (навантаження F1 0,97 проти 0,98, стрес 0,56 проти 0,61). Але на 2900 навчальних вікнах від 27 людей їй бракує даних, щоб самій вивести варіабельність ритму і сплески провідності, які в ознаки закладені з фізіології. Те саме бачили Dzieżyc et al. на WESAD.

9.3. Чому не допомогла попередньо навчена модель

MOMENT навчався на рядах іншої природи з Time Series Pile, і навіть донавчання двох останніх блоків encoder на 2900 вікнах не наздоганяє мережу, навчену з нуля. Прогін із повністю замороженим encoder дав ту саму macro-F1 0,68. Донавчання підняло accuracy і F1 навантаження, але не клас стресу: recall стресу 0,54, найгірший серед трьох. Загальні уявлення про форму ряду не містять

тонких ознак стресу, а 2900 вікон замало, щоб 35-мільйонна модель їх вивчила. Додатково інтерполяція 120 відліків до 512 не додає інформації, а усереднення ембедингів по патчах губить часову структуру сплесків.

9.4. Аналіз помилок

Навантаження впізнається майже безпомилково (recall 96 %, 94 %, 91 %). Уся складність у парі спокій / стрес: F1 стресу 0,43–0,61, плутанина в обидва боки. Причини в даних: реакція на завдання запізнюється на десятки секунд, після завдання збудження спадає не одразу, частина учасників на лабораторний стрес майже не реагує. Важливість ознак XGBoost узгоджується з цим: найбільшу вагу мають інтервал між ударами, температура, амплітуда сплесків, пульс і рівень провідності; ознаки руху важать мало, бо навантаження і так відділяється пульсом і температурою.

9.5. Стабільність і ціна

Діапазон macro-F1 по групах: 0,04 для XGBoost, 0,07 для мережі, 0,11 для MOMENT. Кожен крок угору за складністю коштує на два порядки більше часу навчання й не дає приросту якості. Для носимого пристрою важливі inference і розмір: XGBoost і згорткова мережа працюють за частки мілісекунди без GPU і важать менше 2 MB, MOMENT потребує GPU, 148 MB і 13 мс на вікно.

10. Висновки

1. Виправданий рівень складності для цієї задачі це класична нелінійна модель над ручними ознаками: XGBoost, accuracy 0,90 ± 0,02, macro-F1 0,80 ± 0,02, 1 с навчання без GPU.
2. Згорткова мережа над сирими сигналами (macro-F1 0,77 ± 0,03) підходить близько, але на 34 учасниках не наздоганяє. Узгоджується з Dzieżyc et al. (2020) і Schmidt et al. (2018).
3. MOMENT-1 з донавчанням двох блоків encoder приросту не дав (0,68 ± 0,04, стільки ж, скільки із замороженим encoder): попереднє навчання не покриває сигнали браслета, а ціна (38 хв навчання на GPU, 148 MB, 13 мс на вікно) для носимого пристрою непридатна.
4. Навантаження відділяється легко (F1 0,93–0,98), стрес від спокою важко (0,43–0,61). Це межа даних: запізніла й неоднакова реакція на лабораторні завдання, короткі вікна.
5. Протокол має ділити дані по учасниках. Числа Hongn et al. з випадковим поділом із нашими не порівнювані.

6. Обмеження роботи: 34 учасники, лабораторний стрес, гіперпараметри без валідаційної частини, MOMENT донавчений частково (2 з 8 блоків) і на GPU, решта моделей на CPU.
7. Напрями подальшої роботи: BVP на 64 Гц для мереж, контекст сусідніх вікон, повне донавчання MOMENT або foundation-модель, навчена саме на фізіологічних сигналах, більше учасників через об'єднання з WESAD.

Список джерел

1. Hongn A. et al. Wearable Device Dataset from Induced Stress and Structured Exercise Sessions. Scientific Data 12:520, 2025. DOI 10.1038/s41597-025-04845-9. Дані: PhysioNet v1.0.1, DOI 10.13026/zzf8-xv61.
2. Schmidt P. et al. Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection. ICMI, 2018. DOI 10.1145/3242969.3242985.
3. Dzieżyc M. et al. Can We Ditch Feature Engineering? End-to-End Deep Learning for Affect Recognition from Physiological Sensor Data. Sensors 20(22):6535, 2020. DOI 10.3390/s20226535.
4. Goswami M. et al. MOMENT: A Family of Open Time-series Foundation Models. ICML, 2024. arXiv:2402.03885.
5. Kaya et al. arXiv:2604.12671, 2026.